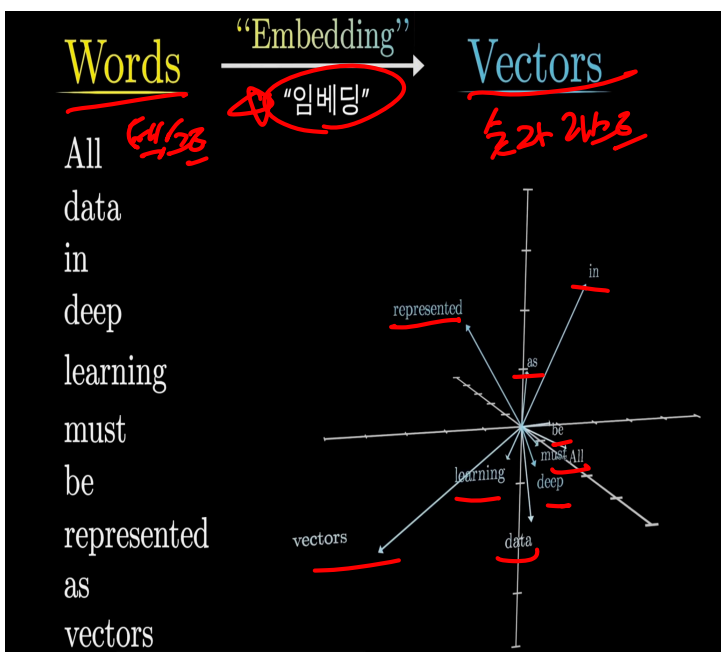

텍스트입력값들 숫자리스트, 벡터로 만드는것

이때 숫자리스트는 벡터의 좌표로볼수있고, 이건 임베딩된 단어들은 고차원의 한점인 좌표로 기하학적 해석이 가능하다.
이러한 임베딩된 벡터를 임베딩 벡터라 한다.

⇒ 초기 임베딩된 벡터의 좌표에서 모델이 학습하면서 가중치 파라미터가 바뀌면서 단어의 좌표가 입력문맥상 비슷한 단어끼리 비슷한 방향과 크기를 가지게 업데이트 된다.

계산은 dot product 연산으로 유사도측정하여 비슷한 값끼리 묶이도록 계산

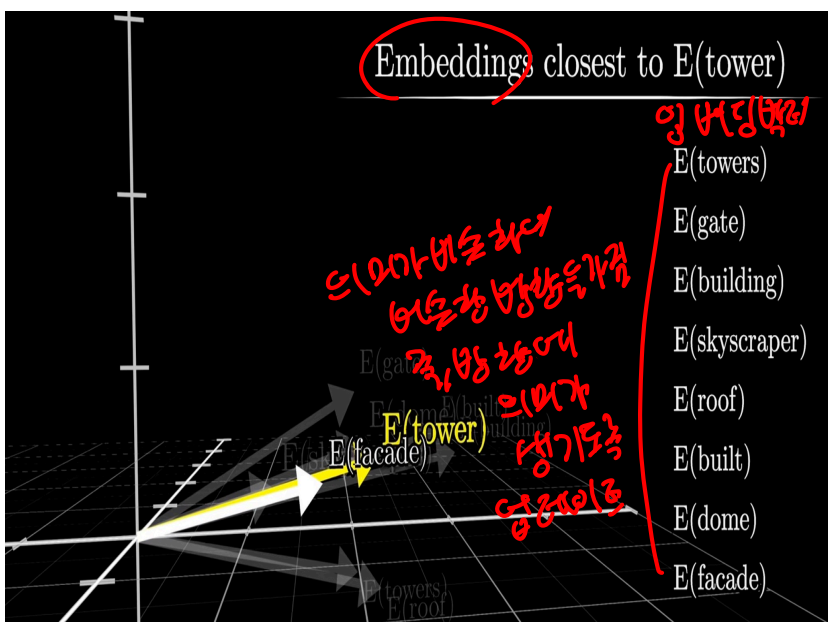

⇒ 즉, 초기 공간속의 의미없는 그냥 단어의 위치만 나타내는 벡터값들이 모델이 학습하면서 어느정도 의미를 가지도록 임베딩벡터가 업데이트 된다., 특정방향이 단어들의 의미를 반영.

비슷한의미 단어들은 비슷한방향들 가지도록 업데이트

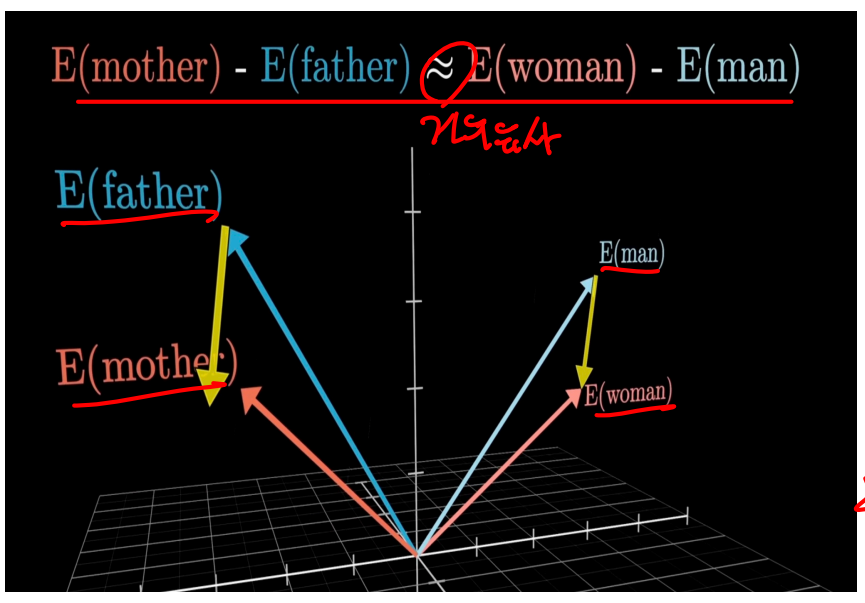

예시로 '남자'를 의미하는 man의 임베딩벡터와 '여자'를 의미하는 woman의 임베딩벡터의 차이인 벡터는 '아빠'를 의미하는 father의 임베딩벡터와 '엄마'를 의미하는 mother의 임베딩 벡터의 차이와 비슷한 크기의 비슷한 방향을 가진다.

즉 E(father)-E(mother)와 E(man)-E(woman) 벡터의 방향은 어떤정보를 가지고있는것이다.

그림에서는 고차원의 시각화를위해 3차원으로 표현했지만 실제로는 E(father), E(man)도 '남성'이라는 성별의 정보를 방향을 가지고 성별의 종연에서는 비슷한 방향을 가진다고 학습임.

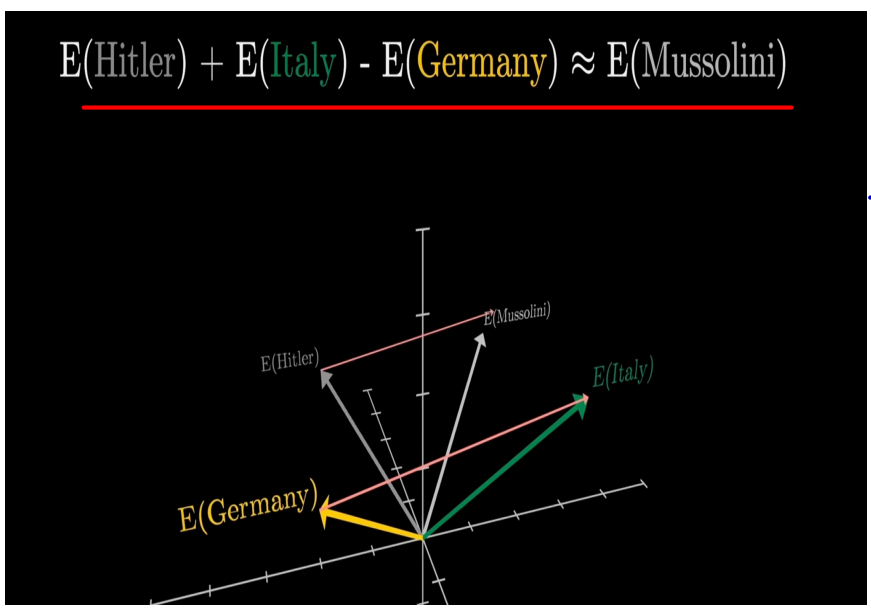

⇒이렇게 임베딩된 벡터는 모델의 파라미터 업데이트를 거치면서 새로운 임베딩 벡터로 업데이트되고 이과정에서 유사한 의미를 가진 임베딩 벡터끼리 유사한방향을가지게되고, 이는 각 임베딩 벡터들이 입력정보의 문맥을통해 단어의 정보를 가진다는결과, 벡터의 연산으로 비슷한 벡터를 생성할수있음을 알수있다.

단어 임베딩이 비슷한 의미를 가지는 방향으로 업데이트되고, 각 업데이트된 임베딩벡터는 유사하다.

업데이트시 내적연산사용하여 유사성 판단후 업데이트

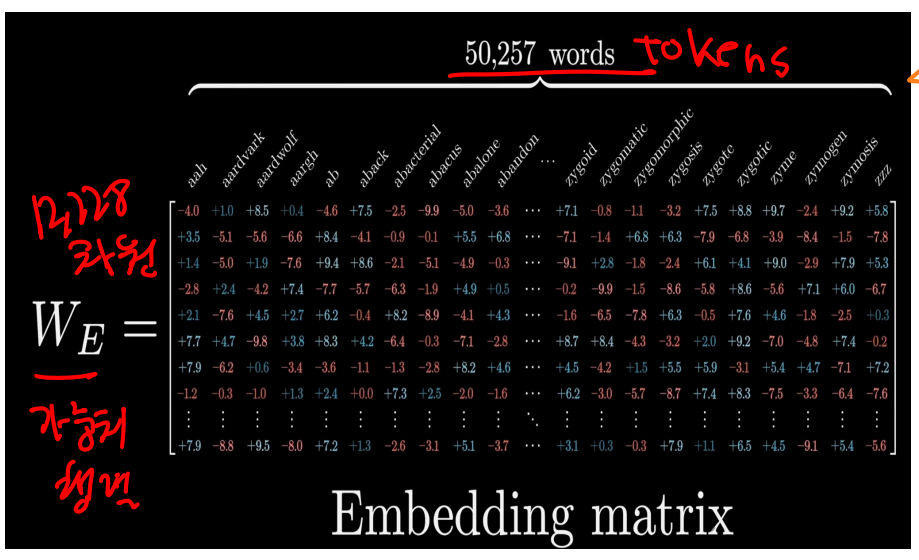

⇒ 모델의 임베딩 행렬은 모델이 학습하여 가지는 임베딩 벡터들의 묶음으로, 입력값이 들어오면 모델이 가지는 Embedding matrix에 각 임베딩벡터들과 내적연산으로 유사도를 계산하여 임베딩화 시켜, 모델의 입력값의 문맥 정보를 얻을 수 있다.

기하적으로보면 50,257 단어들이 임베딩된 고차원 공간에 입력값들 어디에 배치시켜서, 벡터 좌표로 나타낼게 하면 내적연산으로 입력값들 모델이가지는 고차원공간(latent space)의 임베딩벡터들과 다 유사도 다져서 비슷한것끼리 묶여게 배치한다. 물론 병렬 점으로 처리한다.

그럼 비슷한 위치의 임베딩벡터를 사용하여 입력의 new 임베딩벡터의 의미파악 과 문장생성에 대한 생성도 가능해진다.

⇓

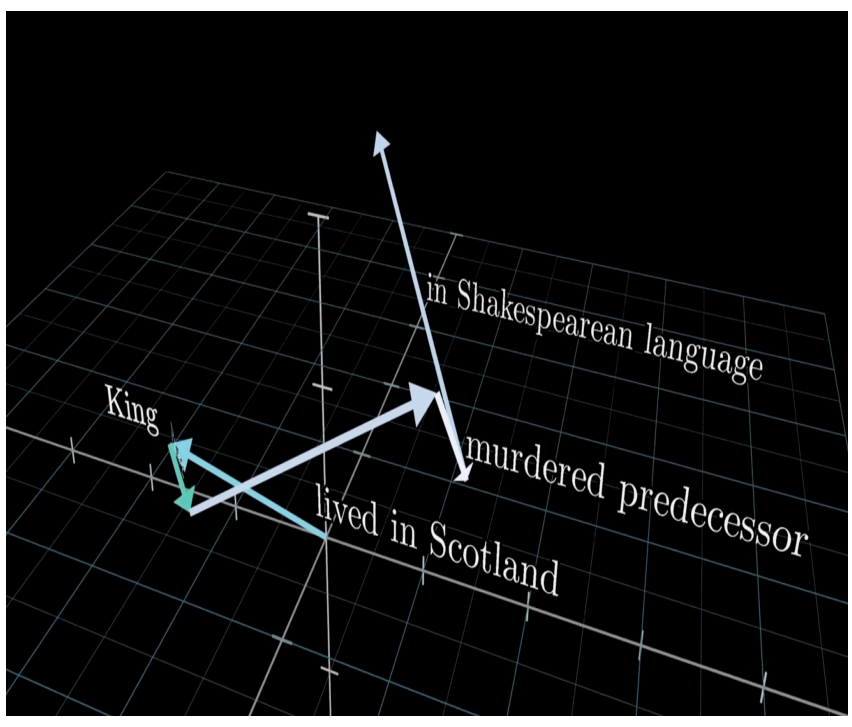

ex) King이라는 입력단어가 토큰화, 임베딩거쳐 임베딩 벡터가되고
→ 이는 여러층을 거쳐서 임베딩벡터의 값이 조금씩 바뀌어 업데이트

결국 스코틀랜드에 살았던 왕으로, 전임왕을 죽이고 그 자리를 차지한 인물로, 셰익스피어식으로 표현된 어떤왕으로 발전된 의미를가진다. King의 임베딩벡터값이 다양한의미를 가지는 값으로 업데이트

⇒ 즉 연결정보로 단어의 맥락과 정의가 되는것이 인간의 사고방식 유사 하다.