경사하강법의 딥러닝 신경망에서의 사용 (feat. 역전파 알고리즘)

모델전체의 파라미터 (가중치, 편향) 의 최적값을 찾기위해 손실함수 값을 최소화하는 방향으로 구함

파라미터 조정 방향

$J(\theta)$ = Loss function

- θ는 모델의 파라미터
- $\arg\min_{\theta} J(\theta)$ → 최솟값 찾는 게 목표가 된 하는 거

↓

어떻게 찾을 거냐? → 경사하강법 사용

- 방향 : 목적 함수의 기울기의 반대방향 → 기울기는 함수값이 가장 빠르게 증가하는 방향을 알려주는 벡터이기 때문에 반대방향을 구한다.
- 크기 : 기울기 × 학습률

→ 목적 함수의 최적해를 찾기위해 얼마나 빠르고 얼만큼 움직일건지

※ 목적함수의 최적화값, 최적해 = 손실함수 + 전체항이 최소값의 되는 값.

↓

그럼 움직이는 방향인 기울기는 어떻게 구할까? → 역전파 알고리즘 사용

- 손실함수 파라미터에 대한 직접적인 함수가 아니라 여러층을 통해 복잡하게 합성된 비선형 합성함수 형태 → 기울기를 한번에 구하지 못하고 각 층 함수의 파라미터에 대해 기울기를 단계적으로 계산

↓

역전파 알고리즘을 통해 마지막층 함수부터 거꾸로 업데이트하며 각 층의 파라미터에 대한 기울기를 동시에 구함

※ 합성함수 미분은 역으로 계산(연쇄법칙)

Q) 손실함수 수식을 풀면 $f(g(h(l \cdots (x))))$ 이런식의 복잡한 합성함수이기 때문에 연쇄법칙

절연 층 에 있는 함수인 마지막층함수부터 거꾸로 계산 하며 최종 적인 손실함수의 계산을 완료한다.

- 파라미터(가중치, 편향)에 대해서 동시에 연쇄법칙으로 편미분하여 계산하고 기울기를 동시에 구한다.

↓ 역전파 알고리즘으로 구한 기울기를 경사하강법을 통해 손실함수의 값이 최소가되는 최적값으로 이동

- 방향 : 기울기 반대
- 크기 : 기울기 × 학습률

↓ 이과정을 반복하여 손실함수 전체에대한 최적값을 찾는다 (모델의 성능을 높임)

↳ 손실함수의 전역 최소 값 (Global minima)를 찾으면 원하는 데이터 변수간의 관계 함수식을 구할수있다

원하는 관계 변수를 제외한 나머지 변수 파라미터 (가중치, 편향)

모델의 성능을 높이기 위한 파라미터의 최적값을 찾기 위해 계속 업데이트

→ 손실함수를 통해 손실함수가 최소(최적)값이 되는 방향으로 모델의 전체 구조(함수)속에 파라미터를 어떻게 조정해야할지 지켜보기

모델의 성능을 높이는(최적의) 함수식 구함 : 산에서 내려올(최단시간)

손실함수 : 내려오는 나침판, 방향, 지도

경사하강법 : 내려가는 방법

> ✅ **경사하강법의 목적은 _"전체 목적함수"의 최소값을 찾는 것**이지, 손실함수 단독의 최소값이 아냐.
> 하지만 손실함수는 목적함수의 중요한 일부이기 때문에, **결국 손실을 최소화하는 방향으로 파라미터를 조정하게 돼.**

🔍 목적함수 vs 손실함수 다시 정리

$$\text{목적함수 } J(\theta) = \underbrace{\frac{1}{n}\sum_{i=1}^{n} \text{Loss}(y_i, \hat{y}i)}_{\text{손실함수}} \text{[redacted]} + \underbrace{\lambda R(\theta)}_{\text{정규화항}}$$

- **손실함수**: 예측 오차 측정 (ex. MSE, CrossEntropy)
- **정규화항**: 모델 복잡도 패널티 부여 (ex. L1, L2)

✅ 경사하강법의 진짜 목적

> **"전체 목적함수를 최소화하는 파라미터 θ를 찾는 것"**
> 즉, 손실 + 정규화 항이 **합쳐진 하나의 함수**를 보고 경사를 따라 내려감.

- 만약 **정규화 항이 없다면**, 경사하강법은 **손실함수만 최소화**하려고 할 거야.
- 정규화 항이 있으면, 손실이 조금 커지더라도 **가중치를 작게 유지하는 방향**으로 움직일 수 있어.