나이브 베이즈 분류기는 베이즈정리를 이용해 만든 확률 분류기다.

나이브베이즈 분류기는 본질적으로 클래스의 확률분포를 사전지식을 통해 가정하여

이후 데이터가 들어왔을 때의 확률분포의 가능도(likelihood)를 구하여 클래스별로 가능도×사전확률을 비교하여 어느 클래스로 분류하는게 가능성이 큰지 확인후 클래스로 분류한다.

지금데이터가 어느클래스 분포로부터 뽑힐 가능성이 큰지

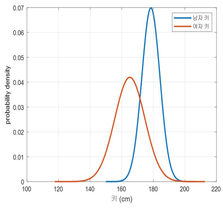

그림 2. training sample들을 통해 얻은 남자, 여자의 키 확률 분포

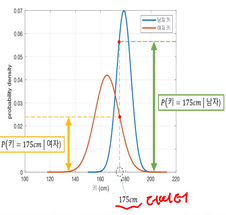

그림 3. 미리 구축해둔 남자, 여자의 키 확률 분포에 test data sample의 값을 대입시켜 본 경우

→ 각 클래스별로 사전지식을 통해 확률분포 가정

→ 가정한 확률분포에 데이터를 통해 각 분포의 가능도를 비교

→ 위 데이터는 175cm는 남자일 가능성이 더 크다

$P(\text{키}=175\text{cm} \mid \text{성별}=\text{남자}) > P(\text{키}=175\text{cm} \mid \text{성별}=\text{여자})$

feature 1개

⇒ 위에서 가능도에 대한 비교만으로는 수집한 데이터에 따라 잘못된 측정을 할 수도 있다. 따라서 정확한 판단을 위해 사전확률 × 가능도(추가정보)를 통해 업데이트하여 기존 배경지식에 추가정보를 곱해줌으로써, 판단 근거는 좀 더 믿을 수 있다

$P(\text{성별}=\text{남자}) \times P(\text{키}=175\text{cm} \mid \text{성별}=\text{남자})$

$P(\text{성별}=\text{여자}) \times P(\text{키}=175\text{cm} \mid \text{성별}=\text{여자})$

비교

사전지식 (prior)	×	추가 정보 (likelihood)

↓

판단 근거

⇒ 여기에 정보가 더 추가된다면?

지금껏 사전정보에 추가정보를 곱해 추가해주었던 것처럼 그 뒤에 추가정보를 덧붙이면 된다.

$P(\text{성별}=\text{남자}) \times P(\text{키}=175 \mid \text{성별}=\text{남자}) \times \underbrace{P(\text{몸무게}=80\text{kg} \mid \text{성별}=\text{남자})}_{\text{추가정보(가능도)}}$

⇒ 베이즈 정리를 통한 판단근거 도출

베이즈 분류기에서 우리가 설계로 원하는 것은 데이터가 어느클래스에 속하는지 판단하는 것이고, 그 판단 근거는 확률로부터 얻을 수 있다.

예를 들어 2개의 클래스 C_1, C_2와 주어진 데이터 x에 대해서 다음과 같은 사후확률로부터 데이터의 클래스를 판단 할 수 있다.

$P(c_i|x)$ for $i = 1, 2$

즉, 만약 $P(c_1|x) > P(c_2|x)$라면 이 샘플의 라벨은 c_1인 것이고, 그렇지 않으면 c_2인 것이다.

이것을 수식으로 표현하면 다음과 같을 것이다.

$$P(c_1|x) >? P(c_2|x)$$

여기서 $A >? B$는 "A가 B보다 큰가?"로 이해하도록 하자.

$$\frac{P(x|c_1)P(c_1)}{p(x)} >? \frac{P(x|c_2)P(c_2)}{p(x)}$$

위 식을 베이즈정리로 바꾸면 다음과 같고

$$P(x|c_1)P(c_1) >? P(x|c_2)P(c_2)$$

위의 분모가 같으니 클래스 분류판단에 어떠한 영향을 미치지않아 무시하면 다음과 같은 사전확률 × 가능도의 비교를 통해 클래스의 판단근거를 알 수 있는 것이다.

⇒ 데이터의 feature가 하나가 아닐경우

클래스는 2개로 같다고 가정한 후, n개의 다중 feature를 가정한다면 아래와 같은 식이 나온다.

$$P(c_1|x_1, x_2, \cdots, x_n) >? P(c_2|x_1, x_2, \cdots, x_n)$$

여기서 $P(c_1|x_1, x_2, \cdots, x_n)$만을 더 전개해보면 다음과 같다.

$$P(c_1|x_1, x_2, \cdots, x_n) = P(c_1)P(x_1|c_1)P(x_2|c_1, x_1)P(x_3|c_1, x_1, x_2) \cdots P(x_n|c_1, x_1, x_2, \cdots x_{n-1})$$

여기서 feature들은 모두 독립적으로 추출된다고 가정해보자.

(그래서 이런 과정을 거치는 분류기를 "naive" Bayes라고 부른다.)

그러면, 가령 $P(x_2|c_1, x_1)$은 다음과 같이 쓸 수 있다.

$$P(x_2|c_1, x_1) = P(x_2|c_1)$$

즉, x_1이 일어나든 말든 x_2의 확률에는 x_1의 발생여부가 조건으로써 영향을 받지 않는다는 것이다. 독립이기때문

그래서 식 (13)을 다시 쓰면,

$$P(c_1|x_1, x_2, \cdots, x_n) = P(c_1)P(x_1|c_1)P(x_2|c_1)P(x_3|c_1) \cdots P(x_n|c_1)$$

$$= P(c_1)\prod_{i=1}^{n} P(x_i|c_1)$$

한마디로 나이브 베이즈 분류기를 사용하게 되면 predicted class $\hat{y}$는 다음과 같다.

$$\hat{y} = argmax_{k \in \{1,2,\cdots,k\}} P(c_k) \prod_{i=1}^{n} P(x_i|c_k)$$

각 클래스별로 가능도×사전확률을 값이 최대 값을 찾아 비교하여 가장큰 값의 클래스로 분류