PCA는 선형 특성변환이며 차원축소라는 얘기로 이해하기 쉽다고 얘기하는데 왜 데이터 셋을 공분산 행렬로 표현하여 선형변환하여 저차원으로 차원축소를 성공하면 공분산행렬의 고유벡터가 중요하기때문에 고유 분해법을 고유값 분해를 통해 고유값과 고유벡터를 뽑아낸다. 고유벡터에 직접을 곱하고 고유값에 직접을 곱하게 되면 고유값에 곱 음수가 되는 경우 방향이 반대로 바뀌게 되기 때문에 고유값은 음수가 아닌 양수만 가지게 된다.

고유벡터로 이루어진 행렬 P 데이터 셋을 직접시키면 자원을 최소화한다. 선형변환시킨다.

고유값과 고유벡터

어떤 벡터를 행렬 A를 곱함을 통해 선형변환시 벡터의 크기만 바뀌고 방향이 바뀌지 않는 벡터라 할 때 그 벡터를 고유벡터라 한다.

가령 $\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}\begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 3 \\ 3 \end{bmatrix} = 3\begin{bmatrix} 1 \\ 1 \end{bmatrix}$

det(행렬식) 벡터 = 선형변환 벡터

아들과 같이 선형변환의 결과가 원래 벡터에 크기만 곱해 지는 벡터를 고유벡터라 하고, 얼마 만큼 곱해지는지 그 값을 고유값이라 한다.

⇒ 즉 임의벡터 $\vec{x}$를 행렬 A로 선형변환 시킨결과 $A\vec{x}$가 상수 배가 된다는 의미이다.

$A\vec{x} = \lambda\vec{x}$

행렬 상수

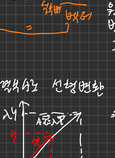

피벗으로 nxn인정방행렬 슬라이딩 해주어서 해주기라는 것 가 중요하면 λ는 A의 고유값이다. $\vec{x}$는 고유벡터이다.

* 행렬식이 선형변환 될 때 크기만 바뀌고 방향은 안 바뀌는 벡터 고유값 고유벡터이다.

다시 말해 고유값과 고유벡터가 무엇보다 중요한 것은, 임의벡터 $\vec{x}$에 행렬식으로 선형변환을 할 때 그 크기만 λ(상수)만큼 변하고, 원래 임의벡터 $\vec{x}$와 평행인 벡터는 무조건이고, 그 크기는 역시나 변했을 뿐이 같다는 것이다.

⇒ 고유값, 고유벡터 계산 ⇒ 고유값 문제 해결하기

$A\vec{x} = \lambda\vec{x}$ 가 있다면, $A\vec{x} = \lambda I\vec{x}$로 표현하여서 식을 정리 $(A - \lambda I)\vec{x} = \vec{0}$ 라는 식이 된다. 이때 $\vec{x}$는 0이외 자명하지 않은 해를 가진다는 얘기이다. 이때 행렬식을 만들 때는 λ를 구해주면 된다.

* 고유값 분해 EVD

⇒ 행렬 을 통해 선형변환을 3가지의 선형 변환으로 나눠어 생각할 수 있다.

어떤 n×n 차원 행렬 A가 다음과 같이 구성되어 있다면

$A = \begin{bmatrix} \lambda_1 a_1 & \lambda_2 a_2 & \cdots & \lambda_n a_n \end{bmatrix} \in R^{n \times n}$

행렬 고유값 고유벡터

위 행렬을 다음과 같이 인식해서 분석한다.

$A = \begin{bmatrix} a_1 & a_2 & \cdots & a_n \end{bmatrix}\begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix}$

대각행렬

* 고유값 분해

임의의 n×n행렬 A가 어떠케의 고유값과 고유벡터를 영위하고 하면

$AV = \lambda V$ 이고 고유벡터 $V = \begin{bmatrix} V_1 & V_2 & \cdots & V_n \end{bmatrix}$, $\Lambda = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix}$

⇒ $AV = \begin{bmatrix} \lambda_1 V_1 & \lambda_2 V_2 & \cdots & \lambda_n V_n \end{bmatrix}$ 이기때문에,

$AV = V\Lambda$, $A = V\Lambda V^{-1}$ 이표현

정방서 자유로움이 분해가능

⇒ 행렬 A로인한 선형변환은 고유벡터 방향으로 고유값만큼 사이 방향 늘어남, λ만큼 스케일 조정하고 다시 원래 차원로 되돌아 제자리로 회전시킨 작업으로 표현 가능하다

* PCA 알고리즘에서 원소 분석 방법이 어떻게 쓰이나?

⇒ PCA에서 공분산 행렬의 고유벡터를 구해, 데이터의 정보를 잘 나타내는 가장 많이 퍼져있는, 분산이 큰 방향 (주성분 특 벡터)를 찾음, 고유값을 보고 주성분 특 벡터의 영향도를 데이터가 얼마나 퍼져있는지 판단, 고유값에 큰 순서대로 주성분을 선택하여, 데이터 정보 손실 최소화 변환과 차원축소

데이터 공분산 =4

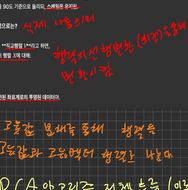

V∧V⁻¹ 벡터의 방향

⇒ $A\vec{x} = \lambda\vec{x}$

원래벡터 고유값 고유벡터

⇒ PCA에서 공분산 행렬 A 고유값 분해 EVD

$A = V\Lambda V^{-1}$, $A = Q\Lambda Q^{-1}$

직교하는 벡터 Q

* 대칭행렬인 공분산 행렬은 $A = A^T$ 이기때문에

$A = V\Lambda V^{-1} = A^T = (V\Lambda V^{-1})^T = (V^{-1})^T\Lambda^T V^T$

$V^{-1} = V^T$, $VV^T = I$ (변치않음)

$V^T V = I$

$\begin{bmatrix} - & V_1^T & - \\ - & V_2^T & - \\ & \vdots & \\ - & V_n^T & - \end{bmatrix}\begin{bmatrix} | & | & & | \\ V_1 & V_2 & \cdots & V_n \\ | & | & & | \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ \vdots & & \ddots & \\ 0 & 0 & 0 & 1 \end{bmatrix}$

⇒ 결론적 $V^{-1} = V^T$ 가 서로 직교하는 벡터라는 의미이다.

∴ $A = V\Lambda V^T$로 직교 나타내고 Q로 바꿔줌 $A = Q\Lambda Q^T$ 가 대칭행렬이기에 고유값 분해 가능

고유값 분해를 통해 특 벡 고유벡터 방향으로 최대분산 찾기 위해, 분산방향 스케일 조정 후 다시 원래 자리 돌아옴.

⇒ 원래 공분산 행렬 A에 대해서 PCA는 고유값 분해시 원래 차원을 제 조 되기 때문 수 있도록 하기 위해 고유 벡터행렬을 직교행렬, 스케일 하고 데이터의 고유벡터 주성분 특 벡터 (정사영) 하여 주성분 특 벡터를 찾도록 한다.

1. PCA에서의 "최대" 기준은 분산

PCA는 원래의 데이터 축을 그대로 쓰지 않고, 데이터의 **분산이 최대인 방향**을 주성분 축(**PC**)으로 새롭게 정의하는 방식이다.

왜 분산 최대화인가?

- 원래 데이터는 x축, y축 기준으로 보여 있었음
- PCA는 공분산 행렬을 고유값 분해하여, → 고유벡터 방향으로 새로운 축 생성
- 즉, 데이터를 새로운 축으로 회전시켜서 표현하는 것

이 회전은 **직교 (orthogonal rotation)**이기 때문에 기존 축들을 90도 기준으로 돌아가, 스케일만 조정됨.

이상적 의미

수학적으로보면? 식과 비슷하다

고유벡터를 **직교행렬 (서로간 수직)**으로 하면 데이터의 형태 그대로 유지.

행렬식 선형변환 (회전)으로 변화시킴.

이 과정은 **회전되지 않은 데이터**를 **회전된 데이터**로 바꾸는 것.

$Z = XV$

즉, 고유벡터 방향대로 회전된 데이터이다.

⇒ 고유값 분해를 통해 행렬을 고유값과 고유벡터 형태로 나눔다

* P(A 알고리즘 전개 흐름. (이론)

PCA에서 파악하려는 고유벡터의 의미적 이유다

고유벡터의 크기는 다르지만, 방향은 같음하기에 정규화

저차원 공간인 고유벡터 크기 1, PCA 회귀와 목표 인 분산최대화를 라그랑지 승수법으로 풀면 고유값 문제가 된다.

최적 화 목적

⇒ $\max_{w} w^T \Sigma w$, s.t. $\|w\|=1$, $w^T w = 1$

⇒ 라그랑지 함수

$L(w, \lambda) = w^T \Sigma w - \lambda(w^T w - 1)$

$\frac{\partial L}{\partial w} = 2\Sigma w - 2\lambda w = 0$

공분산행렬 수정

$\Sigma w = \lambda w$ ⇒ 고유 벡터 ⇒ 고유값 문제 (선형) ∴ 고유값 인식 결론

$z = w^T x$

데이터를 고유벡터 w로 투영.

$Var(z) = \frac{1}{n}\sum(w^T x - 0)^2$

정규화하여 0

주성분 특 벡터 정리

⇒ $Var(z) = \frac{1}{n}\sum(w^T x_i)(w^T x_i)$

⇒ $\frac{1}{n} w^T \left(\sum x_i x_i^T\right) w$

공분산행렬 $\Sigma = \frac{1}{n}\sum x x^T$

$Var(z) = w^T \Sigma w$

공분산 특 벡터 정리

문제 최적화 문제로 가정하여 공분산 행렬 → 고유값 문제로 바뀜

목표: 공분산 행렬의 고유값 문제로 바뀜

여러 번 (방법)

⇒ 모든 주성분 풀어 봤으니 공분산 행렬을 고유값 문제 ⇒ 고유값 벡터와 고유벡터 방법

$\Sigma = V\Lambda V^T$

즉, PCA는 최대 분산 방향을 찾는 최적화 문제 이다, 이 목적을 라그랑지 승수 법으로 풀면 고유값 문제로 바뀜 → PCA는 공분산 행렬의 고유 값 문제

$\det(\Sigma - \lambda I) = 0$ 인 행렬식 문제를 풀어 각 고유값 λ를 구하고,

행렬 선형

고유값 λ 에대하여 $\Sigma\vec{x} = \lambda\vec{x}$ 를 풀면 각 고유값 λ 에대하여 고유벡터 $\vec{x}$ 를 구할 수 있다.

방향의 크기 방향의 방향 고유벡터 행렬 선형

이렇게 구한 고유값과 고유벡터라 고유벡터 (주성분 특)도 선형 변환, 데이터 벡터를 고유벡터 (주성분 특)에 투영 (내적하여 계산) 하여 데이터의 정보를 각 보존 하는 방법으로 차원 축소한다.

PCA 알고리즘

ㄱ) 이때! 고윳값이 (주성분 축) 에 투영해야, 좌표는 흩어져면서 오차가 데이터 간 가장 구조 정보를 제대로 잘 유지 할수 있을까?

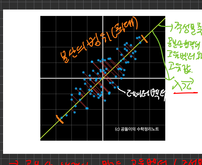

ㄱ) 공분산 행렬의 고윳값이 (주성분 축) 중에서, 어디만 해서가 데이터를 투영시켜, 차원을 축소해, 차원 데이터 구조 정보 (분산)를 잘 유지 해 놓게가 데이터를 최대 특징 뽑아내는 과정이라 하는거 같는 것이다

이거 활용해 줄(가중치)

PCA 실제 적용 + 의미

ex) 국어점수 | 수학 점수

100	80
70	60
30	50
⋮	⋮

=>

중심점 (비중평균) : (수학 60%, 국어 80%), (수학 70%, 국어 60%)

$(100\times0.4)+(80\times0.6) = [100,80]\cdot[0.4,0.6]^T$

$(70\times0.4)+(60\times0.6) = [70,60]\cdot[0.4,0.6]^T$

$(30\times0.4)+(50\times0.6)$

2차원 → 1차원

ㄱ) 1차원으로 줄인 새로운 데이터 특징 차원을 보니 고객이 두 번째 데이터 변경으로 복수있다 ㅋ

ㄱ) 이 차원 차원의 줄여 데이터를 투영 시킨다 $[0.4, 0.6]$ 이거라는 행렬.

ㄱ 주성분 벡터 (고윳값 큰 순서대로) 데이터의 전체 분산을 최대로 보존하는 방향을 찾아내는 방법

ㄱ 국어 + 수학 점수를 변경시켜 중심점 잡을 새로운 특징 차원 만듦

시각적으로 보면

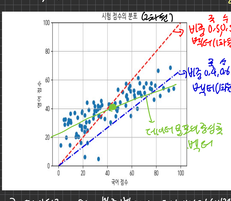

ㄱ) 데이터를 잘 보존 변경에 특징시키는 (벡터) 방향에 가장 이때 각 점수에 곱할 중심점수를 선택하는 것

ㄱ) 축 하나가 잡고자 하는 목적?

데이터의 변동을 어떤 방향에 내재(특징) 하는지에 의거해 결과 (데이터 정보 손실최소)를 얻 축수요와

내적적 변동 축을 잡을때, 데이터 분포의 중심을 중심축으로 하는 변동을 잡는가 줄지 않는가?

ㄱ) 주성분 축 변동의 잘 표현시키는 벡터.

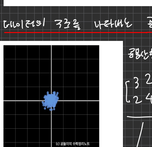

공간화

변동의 방향에 의한 공간 조정

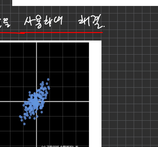

ㄱ 데이터의 구조를 나타내는 공분산 행렬을 사용하여 회전

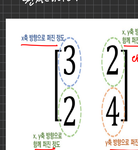

회전 전 데이터

공분산 행렬

$\begin{bmatrix} 3 & 2 \\ 2 & 4 \end{bmatrix}$

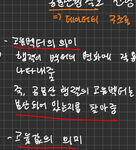

공분산 행렬로 선형 변환된 데이터

ㄱ) 데이터의 구조를 나타내준다.

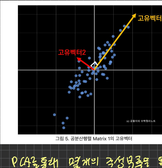

그림 4. 공분산행렬 Matrix 의 각 원소들이 의미하는 것

- 고윳벡터의 의미

ㄱ) 행렬에 벡터에 변화시킬 때 흩어진 축들의 방향을 나타내줌

즉, 공분산 행렬의 고윳벡터는 데이터가 어떤 방향으로 분산되어 있는지를 알려줌

- 고윳값의 의미

고윳벡터의 방향으로 얼마만큼 퍼져있는지 (분산)의 크기를 의미

즉, 고윳값이 큰 순서대로 주요 방향을 정렬 하면 결과적으로 중요한 순서대로 주성분들을 구성하게 됨

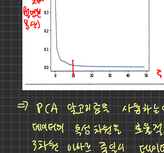

그림 5. 공분산행렬 Matrix 의 고유벡터

ㄱ) 공분산 행렬 $\begin{bmatrix} 3 & 2 \\ 2 & 4 \end{bmatrix}$ 의 고윳벡터 이다.

즉, 우리는 데이터 벡터를 어떤 방향에 내재 하는지에 의거해 줄지 라는 목적을 통해 변 할 데이터의 변화의 공분산 행렬의 고윳값 분해를 통해 고윳값과 고유 벡터를 구하는 것이다.

PCA를 통해 몇개의 주성분을 유지 차원 축소를 해야하나?

어디까지 차원축소를 해야 데이터 정보를 보존하면서, 성능 및 복잡도 감소할까

ㄱ 그래프를 보면 주성분이 10개 이상 지정 가지는 각 주성분의 고윳값 (설명된 분산) 의 크기가 갑자기 떨어지지만 이후는 각 주성분이 설명하는 데이터 분산의 영향이 거의 없으므로 주성분도 10개가 적당하다

ㄱ) PCA 알고리즘은 사용하는이유

데이터의 용량 차원을 효율적으로 줄여 모델의 학습속도와 저장공간을 극적으로 줄일 수 있다.

3차원 이상의 복잡한 데이터 시각화가 용이하다.

데이터의 많은 노이즈를 생겨 차원으로 인해 차원의 저주를 줄인 모델 성능 개선을 도모할 수 있다.

과적합 및 학습 속도 향상 모델의 일반화 성능을 높여준다